





Práctico ensamblaje y anotación genómica

Luisa Berná, PhD lberna@pasteur.edu.uy

Unidad de Bioinformática - Laboratorio de Biología de Apicomplejos Institut Pasteur de Montevideo

Laboratorio de Genómica Evoluitva - Facultad de Ciencias, UDELAR.

Objetivos

- Aprender a ensamblar genomas utilizando distintos tipos de secuencias y estrategias
- Afianzar conceptos sobre las distintas tecnologías de secuenciación
- Afianzar conceptos sobre algoritmos de ensamblaje
- Aprender a realizar anotación automática, y entender sus virtudes y limitaciones.


Cómo?

- Ensamblando el genoma de un organismo modelo (levadura) para el cual existen diferentes tipos de datos
 - Illumina (paired-end)
 - Nanopore
- Haciendo una predicción de genes
- A través de la práctica de distintas herramientas y la comparación y discusión de los resultados obtenidos

Modelo de estudio

Para este práctico se utilizará la levadura (*Saccharomyces cerevisiae*). Este organismo tiene varias ventajas que lo hacen interesante para realizar un práctico de ensamblaje y anotación:

- ★ Ampliamente conocido e interesante (pan/vino/cerveza)
- ★ Eucariota (complejidad intermedia)
- ★ Tamaño genómico reducido (12Mb)
- ★ 16 Cromosomas
- ★ Genes con Intrones (~10%)
- ★ EXISTEN datos disponibles de varias plataformas (illumina/PacBio/Nanopore)



Complete genomic and transcriptional landscape analysis using third-generation sequencing: a case study of *Saccharomyces cerevisiae* CEN.PK113-7D

Piroon Jenjaroenpun^{1,†}, Thidathip Wongsurawat^{1,†}, Rui Pereira², Preecha Patumcharoenpol¹, David W. Ussery^{1,3}, Jens Nielsen^{2,4} and Intawat Nookaew^{1,2,3,*}

¹Department of Biomedical Informatics, College of Medicine, University of Arkansas for Medical Sciences, Little Rock, AR 72205, USA, ²Department of Biology and Biological Engineering, Chalmers University of Technology, Gothenburg SE-412 96, Sweden, ³Department of Physiology and Biophysics, College of Medicine, The University of Arkansas for Medical Sciences, Little Rock, AR 72205, USA and ⁴Novo Nordisk Foundation Center for Biosustainability, Technical University of Denmark, DK2800 Lyngby, Denmark

Received September 11, 2017; Revised January 03, 2018; Editorial Decision January 04, 2018; Accepted January 05, 2018

1 - Pre-procesamiento de secuencias

- Descargar datos // Obtener datos a partir de secuenciaciones
- Analizar la calidad de las secuencias
- Filtrar si es necesario
- Re-analizar la calidad para determinar si los filtros utilizados fueron adecuados

2 - Ensamblaje DE NOVO

Vamos a ensamblar *de novo* un genoma de *Saccharomyces cerevisiae* usando reads obtenidos a partir de tecnologías diferentes:

- Illumina
- Nanopore ONT

Vamos a utilizar distintos programas y comparar sus resultados

3- Evaluación de los ensamblajes

- + infoseq
- + YASS
- + BLAST
- + Assemblytics
- + BUSCO

4- Búsqueda de genes

AUGUSTUS

Augustus [gene prediction]


Bioinformatics Group of the Institute for Mathematics and Computer Science of the University of Greifswald

web interface WebAUGUSTUS accuracy results download AUGUSTUS data sets predictions references




AUGUSTUS is a program that predicts genes in eukaryotic genomic sequences. It can be run on this web server, on a new web server for larger input files or be downloaded and run locally. It is open source so you can compile it for your computing platform. You can now run AUGUSTUS on the German MediGRID. This enables you to submit larger sequence files and allows to use protein homology information in the prediction. The MediGRID requires an instant easy registration by email for first-time users.

Formatos



Algunas definiciones



 Long reads – Much longer reads! Can thus improve de novo assembly, mapping certainty, transcript isoform identification, and detection of structural variants

Formatos

- + FASTA
- + FASTQ
 - + Calidad PHRED

FASTA

Un formato de texto plano utilizado para representar secuencias de nucleótidos o proteínas. Los nucleótidos se representan con las letras A,C,G,T y los aminoácidos con el código de una letra:

+ Encabezado

descripción en una única línea que comienza con el símbolo '>'. No hay espacios entre el '>' y el comienzo de la descripción. Puede contener un simple identificador o una descripción más compleja y comentarios

+ Cuerpo

la propia secuencia representada por la sucesión de letras. Pueden ir todas en una línea o en bloques (en general de 80 caracteres)

FASTA

>gi|5524211|gb|AAD44166.1| cytochrome b [Elephas maximus maximus]
LCLYTHIGRNIYYGSYLYSETWNTGIMLLLITMATAFMGYVLPWGQMSFWGATVITNLFSAIPYIGTNLV
EWIWGGFSVDKATLNRFFAFHFILPFTMVALAGVHLTFLHETGSNNPLGLTSDSDKIPFHPYYTIKDFLG
LLILILLLLLALLSPDMLGDPDNHMPADPLNTPLHIKPEWYFLFAYAILRSVPNKLGGVLALFLSIVIL
GLMPFLHTSKHRSMMLRPLSQALFWTLTMDLLTLTWIGSQPVEYPYTIIGQMASILYFSIILAFLPIAGX
IENY

multiFASTA

- Un archivo puede contener más de una secuencia. Cada secuencia comienza con su encabezado y tiene su cuerpo
- + Un multifasta puede tener miles y miles de secuencias (por ejemplo uno con todas las proteínas de un genoma)

>SEQUENCE 1


MTEITAAMVKELRESTGAGMMDCKNALSETNGDFDKAVQLLREKGLGKAAKKADRLAAEG
LVSVKVSDDFTIAAMRPSYLSYEDLDMTFVENEYKALVAELEKENEERRRLKDPNKPEHK
IPQFASRKQLSDAILKEAEEKIKEELKAQGKPEKIWDNIIPGKMNSFIADNSQLDSKLTL
MGQFYVMDDKKTVEQVIAEKEKEFGGKIKIVEFICFEVGEGLEKKTEDFAAEVAAQL
>SEQUENCE_2

SATVSEINSETDFVAKNDQFIALTKDTTAHIQSNSLQSVEELHSSTINGVKFEEYLKSQI ATIGENLVVRRFATLKAGANGVVNGYIHTNGRVGVVIAAACDSAEVASKSRDLLRQICMH

FASTQ Fasta Quality

- Es el archivo que obtenemos de las distintas plataformas de secuenciación
- Posee información de secuencia (como el archivo FASTA:

FASTQ encabezado




illumina'

@EAS139:136:FC706VJ:2:2104:15343:197393 1:Y:18:ATCACG

EAS139	the unique instrument name
136	the run id
FC706VJ	the flowcell id
2	flowcell lane
2104	tile number within the flowcell lane
15343	'x'-coordinate of the cluster within the tile
197393	'y'-coordinate of the cluster within the tile
1	the member of a pair, 1 or 2 (paired-end or mate-pair reads only)

Flow Cell Images



FASTQ Calidad

PHRED SCORE es una medida de calidad Q

P es la probabilidad de que un nucleótido haya sido asignado

incorrecta

$$Q = -10 \, \log_{10} P \qquad P = 10^{rac{-Q}{10}}$$

Phred quality scores are logarithmically linked to error probabilities

Phred Quality Score	Probability of incorrect base call	Base call accuracy
10	1 in 10	90%
20	1 in 100	99%
30	1 in 1000	99.9%
40	1 in 10,000	99.99%
50	1 in 100,000	99.999%
60	1 in 1,000,000	99.9999%


FASTQ Calidad - código ASCII

(eres ASCII
00	NULL	(carácter nulo)
01	SOH	(inicio encabezado)
02	STX	(inicio texto)
03	ETX	(fin de texto)
04	EOT	(fin transmisión)
05	ENQ	(consulta)
06	ACK	(reconocimiento)
07	BEL	(timbre)
08	BS	(retroceso)
09	HT	(tab horizontal)
10	LF	(nueva línea)
11	VT	(tab vertical)
12	FF	(nueva página)
13	CR	(retorno de carro)
14	SO	(desplaza afuera)
15	SI	(desplaza adentro)
16	DLE	(esc.vínculo datos)
17	DC1	(control disp. 1)
18	DC2	(control disp. 2)
19	DC3	(control disp. 3)
20	DC4	(control disp. 4)
21	NAK	(conf. negativa)
22	SYN	(inactividad sínc)
23	ETB	(fin bloque trans)
24	CAN	(cancelar)
25	EM	(fin del medio)
26	SUB	(sustitución)
27	ESC	(escape)
28	FS	(sep. archivos)
29	GS	(sep. grupos)
30	RS	(sep. registros)
31	US	(sep. unidades)
127	DEL	(suprimir)

	200		res A mible		
32	espacio	64	@	96	•
33	!	65	A	97	a
34	"	66	В	98	b
35	#	67	C	99	С
36	\$	68	D	100	d
37	%	69	E	101	е
38	&	70	F	102	f
39		71	G	103	g
40	(72	Н	104	h
41)	73	- 1	105	i
42	*	74	J	106	i
43	+	75	K	107	k
44		76	L	108	1
45	V-1	77	M	109	m
46		78	N	110	n
47	- 1	79	0	111	0
48	0	80	Р	112	p
49	1	81	Q	113	q
50	2	82	R	114	r
51	3	83	S	115	S
52	4	84	T	116	t
53	5	85	U	117	u
54	6	86	V	118	٧
55	7	87	W	119	W
56	8	88	Х	120	X
57	9	89	Y	121	у
58	:	90	Z	122	Z
59	;	91	[123	{
60	<	92	Ī	124	i
61	=	93	1	125	}
62	>	94	۸	126	~
63	?	95	_	1	

		AS	SCII e	xtend	ido		
128	Ç	160	á	192	L	224	Ó
129	ü	161	í	193	1	225	ß
130	é	162	Ó	194	Т	226	Ô
131	â	163	ú	195	ŀ	227	Ò
132	ä	164	ñ	196	_	228	õ
133	à	165	Ñ	197	+	229	Õ
134	å	166	3	198	ã	230	μ
135	Ç	167	0	199		231	þ
136	ê	168	5	200	L	232	Þ
137	ë	169	®	201	IF	233	Ú
138	è	170	7	202	<u>II</u>	234	Û
139	Ï	171	1/2	203	TE	235	Ù
140	î	172	1/4	204	T	236	ý
141	ì	173	i	205	-	237	Ý
142	Ä	174	**	206	#	238	600
143	A	175	>>	207	-	239	500
144	É	176	***	208	ð	240	=
145	æ	177	2000	209	Ð	241	±
146	Æ	178		210	Ê	242	_
147	ô	179		211	Ë	243	3/4
148	Ö	180	+	212	È	244	1
149	ò	181	Á	213	1	245	S
150	û	182	Â	214	i	246	÷
151	ù	183	À	215	î	247	3 0
152	ÿ	184	©	216	Ï	248	0
153	Ö	185	4	217	L	249	-
154	Ü	186	1	218	г	250	138
155	Ø	187	7	219		251	1
156	£	188	j	220		252	3
157	Ø	189	¢	221	T	253	2
158	×	190	¥	222	i	254	
159	f	191	٦	223		255	nbsp

FASTQ Calidad - código ASCII + 33



@SSR34543212 Saccharomyces cerevisiae ATTCGCCAGGTCTAG

Phred score Q

Phred score Q

@SSR34543212 Saccharomyces cerevisiae CEN.PK113-7D ATTCGCCAGGTCTAG

+ BC#4>RTWX!![KU>

Base1: Phred value=33, sumamos 33 = 66 (ascii 66 = B)

Base2: Phred value=34, sumamos 33 = 67 (ascii 67 = C)

Base3: Phred value=2, sumamos 33 = 35 (ascii 35 = #)

Base4: Phred value=19, sumamos 33 = 52 (ascii 52 = 4)

Base15: Phred value= 29, sumamos 33 = 62 (ascii 62 = >)

Qué pasa con los reads largos?


Mayor proporciones de errores

Errores aleatorios

Mejoras en los algoritmos que realizan la asignación de bases

Repositorios públicos - banco de datos

- SRA (Sequence Reads Archive)
 Un repositorio público con datos de secuenciaciones de distintas plataformas
- GEO (Gene Expression Omnibus)
 Un repositorio público con datos de expresión génica (Microarrays, NGS)



metagenomic and environmental surveys. SRA stores raw sequencing data and alignment information to enhance reproducibility

Announcement

NIH Request for Information (RFI) on SRA data format changes and plans.

Getting Started	Tools and Software	Related Resources	
How to Submit	Download SRA Toolkit	Submission Portal	
How to search and download	SRA Toolkit Documentation	Trace Archive	
How to use SRA in the cloud	SRA-BLAST	dbGaP Home	
Submit to SRA	SRA Run Browser	<u>BioProject</u>	
	SRA Run Selector	BioSample	

and facilitate new discoveries through data analysis.


fastq-dump

Convierte datos SRA en formato FASTQ

fastq-dump [opciones]
<IDFNTIFICADOR>

Ej:

fastq-dump --splite-files SRR6074044.sra



SRA Toolkit Documentation

SRA Toolkit Installation and Configuration Guide
Protected Data Usage Guide

Frequently Used Tools:

fastq-dump: Convert SRA data into fastq format

prefetch: Allows command-line downloading of SRA, dbGaP, and ADSP data

sam-dump: Convert SRA data to sam format

sra-pileup: Generate pileup statistics on aligned SRA data

vdb-config: Display and modify VDB configuration information

vdb-decrypt: Decrypt non-SRA dbGaP data ("phenotype data")

Additional Tools:

abi-dump: Convert SRA data into ABI format (csfasta / qual)

illumina-dump: Convert SRA data into Illumina native formats (gseq, etc.)

sff-dump: Convert SRA data to sff format

sra-stat: Generate statistics about SRA data (quality distribution, etc.)

vdb-dump: Output the native VDB format of SRA data.

vdb-encrypt: Encrypt non-SRA dbGaP data ("phenotype data")
vdb-validate: Validate the integrity of downloaded SRA data

fastq-dump


Convierte datos SRA en formato FASTQ

fastq-dump [opciones]
<IDFNTIFICADOR>

Ej:

fastq-dump --splite-files SRR6074044.sra

selected with the BluePippin system with a cut-off value of 9000 bp. We used one SMRTcell™ to sequence the DNA library on the PacBio Sequel instrument using the Sequel 2.0 polymerase and 600 min of movie time. The high quality PacBio reads are deposited in an SRA database under Bio-Project:PRJNA398797, SRP116559.



Obtención de datos de SRA

- Usando PREFETCH
 prefetch SRR8922830
 (genera un archivo SRR8922830.sra)
- Usando fastq-dump
 fastq-dump –Z –X 10 SRR8922830
 (imprime en pantalla (opción -Z) las primeras 10 secuencias (-X 10)
- Usando WGET
 Wget https://sra-downloadb.st-va.ncbi.nlm.nih.gov/sos1/sra-pub-run-12/SRR6352892/SRR6352892.1
- Usando FTP
 ftp://ftp-trace.ncbi.nih.gov/sra/sra-instant/reads/ByRun/sra/SRR/SRR607/S
 RR6074044/SRR6074044.sra

Usando WGET



Get the latest research from NIH: https://www.nih.gov/coronavirus. Find NCBI SARS-CoV-2 literature, sequence, and clinical content: https://www.ncbi.nlm.nih.gov/sars-cov-2/.

Direct RNA-seg, poly-A, ethanol, replicate 4 (SRR6352892)

Metadata Analysis Reads Data access

SRA archive data

SRA archive data is normalized by the SRA load process and used by the <u>SRA Toolkit</u> to read and produce formats like FASTQ, SAM, etc. The default toolkit configuration enables it to find and retrieve SRA runs by accession.

Public SRA files are now available from GCP and AWS cloud platforms as well as from NCBI. Access to most data in the cloud requires a user account with the cloud service provider. The user's account will incur costs for cloud compute or to copy data outside of the specified cloud service region.

Туре	Size	Location	Name	Free Egress	Access Type
run	769,543 Kb	NCBI	https://sra-downloadb.be-md.ncbi.nlm.nih.gov/sos2/sra-pub-run-11/SRR6352892/SRR6352892.1	worldwide	anonymous
		NCBI	https://sra-downloadb.st-va.ncbi.nlm.nih.gov/sos1/sra-pub-run-12/SRR6352892/SRR6352892.1	worldwide	anonymous
		AWS	s3://sra-pub-run-5/SRR6352892/SRR6352892.1	s3.us-east-1	aws identity
		GCP	gs://sra-pub-run-5/SRR6352892/SRR6352892.1	gs.US	gcp identity

N50 size

Def: 50% of the genome is in contigs larger than N50



N50 size = 30 kbp
$$(300k+100k+45k+45k+30k = 520k >= 500kbp)$$

Note:

N50 values are only meaningful to compare when base genome size is the same in all cases